Вводный курс по Big Data. Обучение в записи

Урок 2. Семинар: Введение в Большие Данные

Оглавление

Семинар. Установка и настройка окружения Anaconda

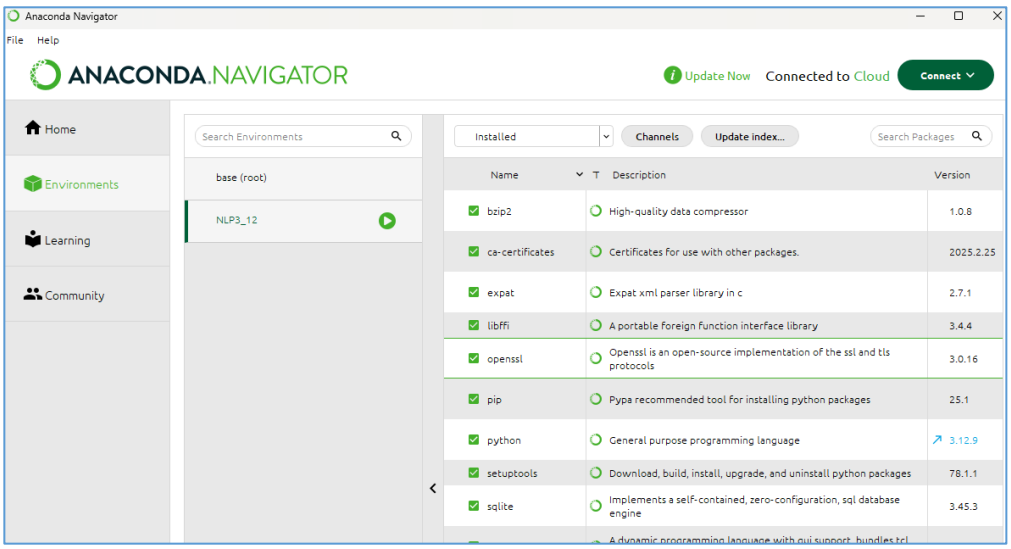

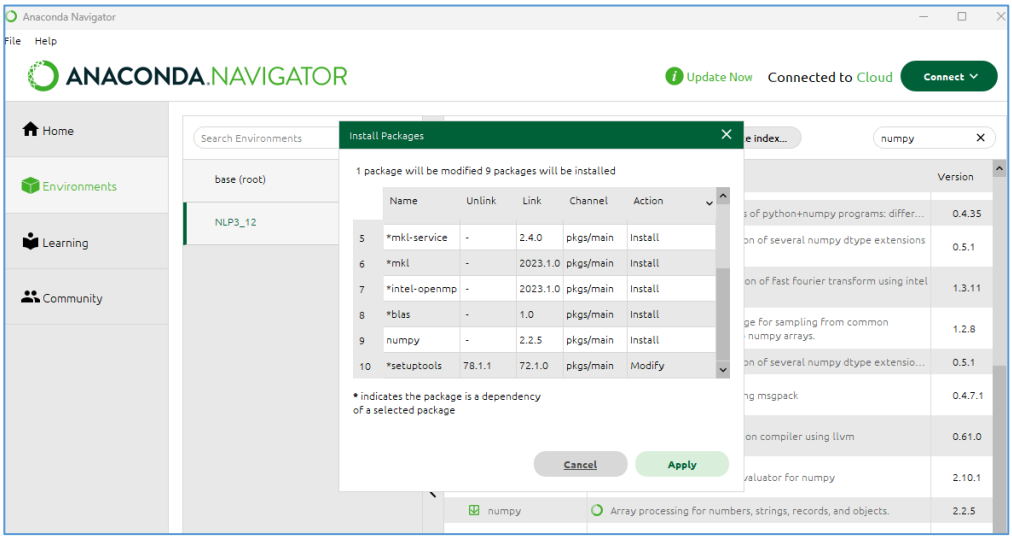

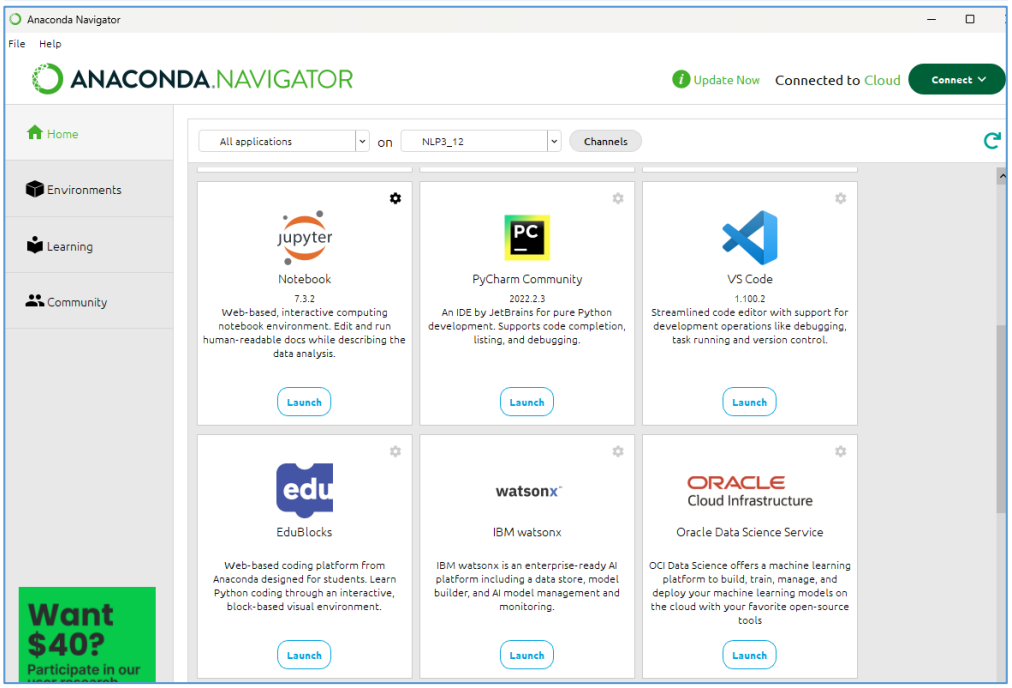

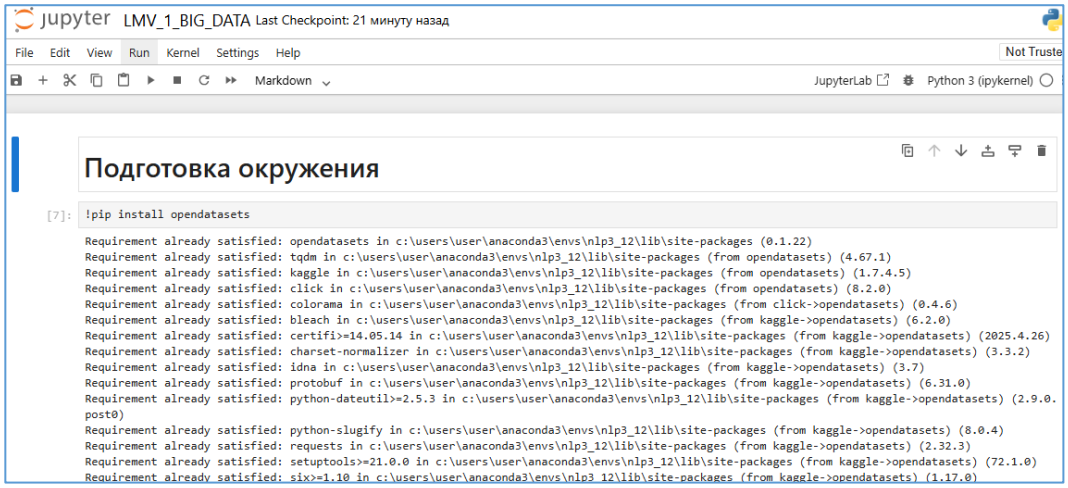

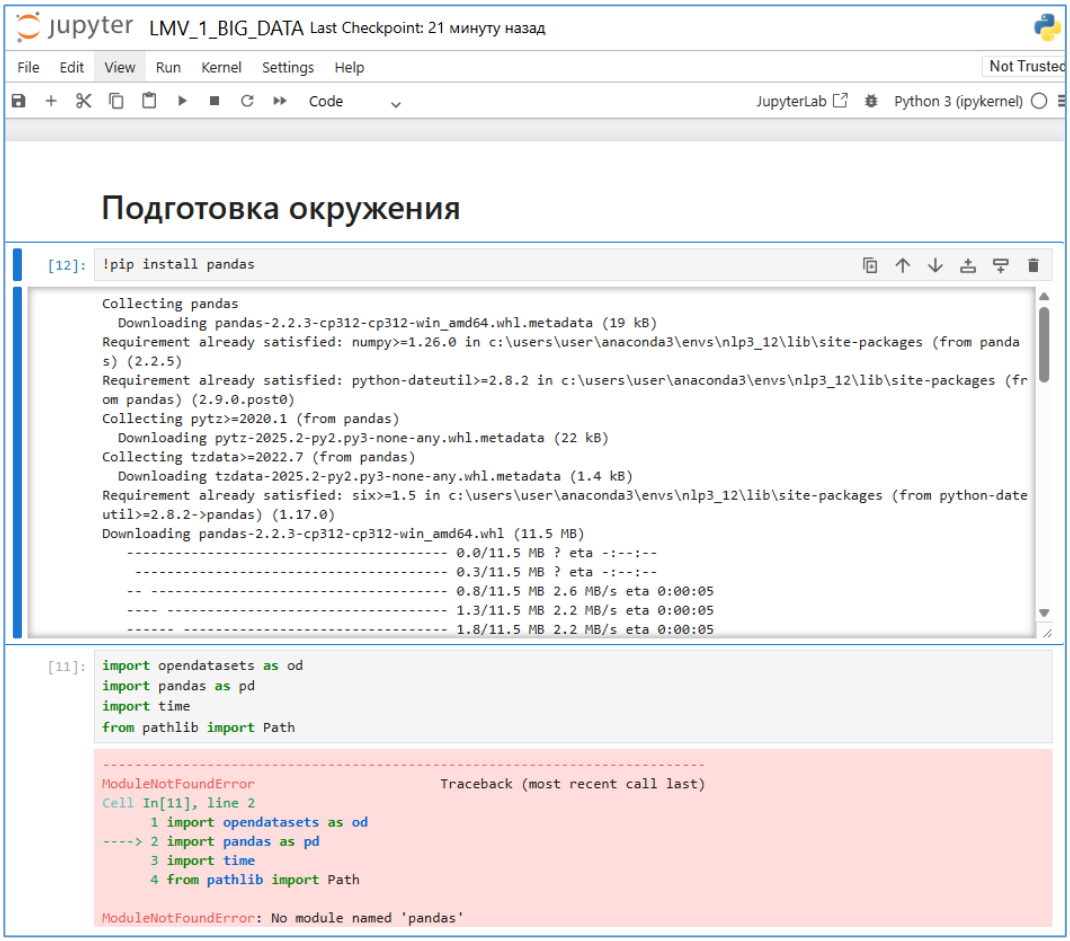

Установка Pandas и загрузка ключа (токена) Kaggle …

Семинар. Выполнение практических задач

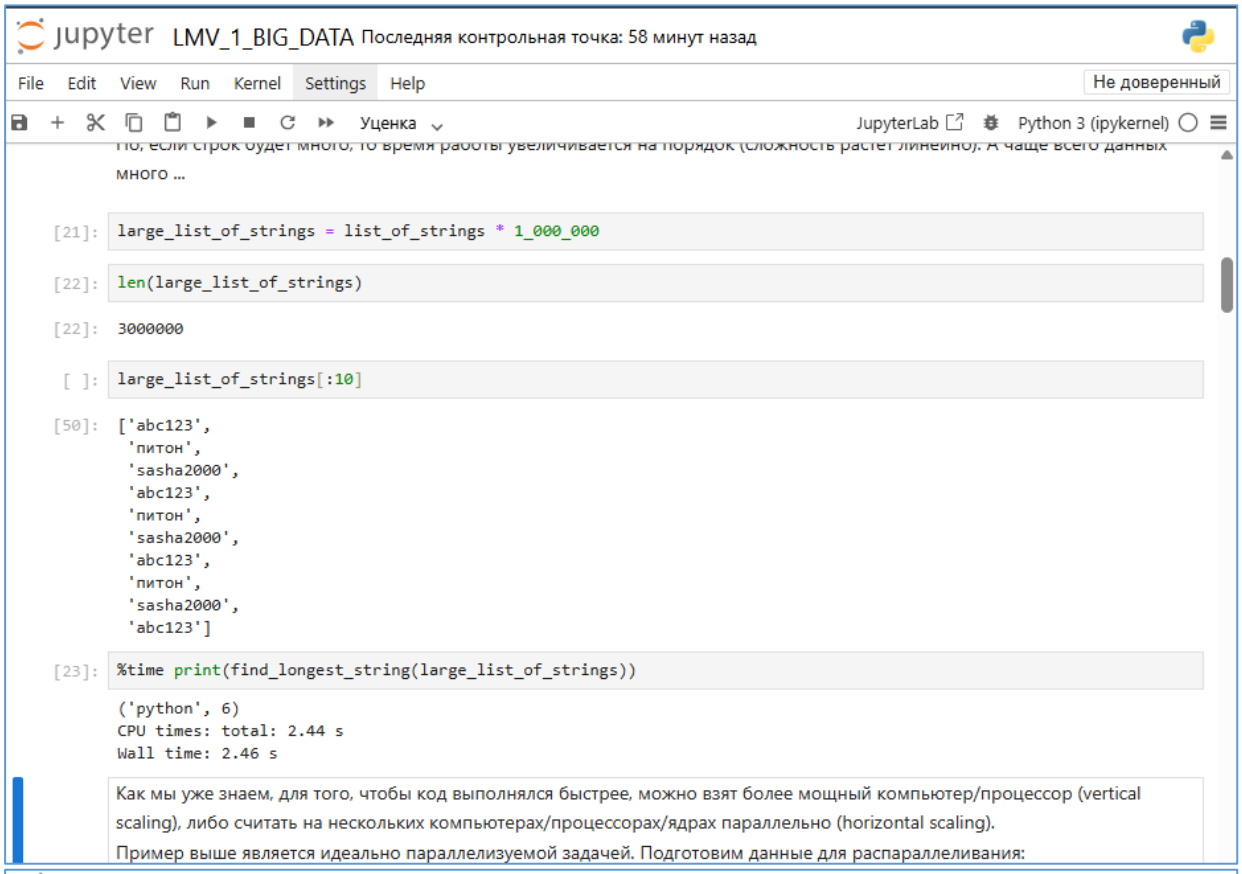

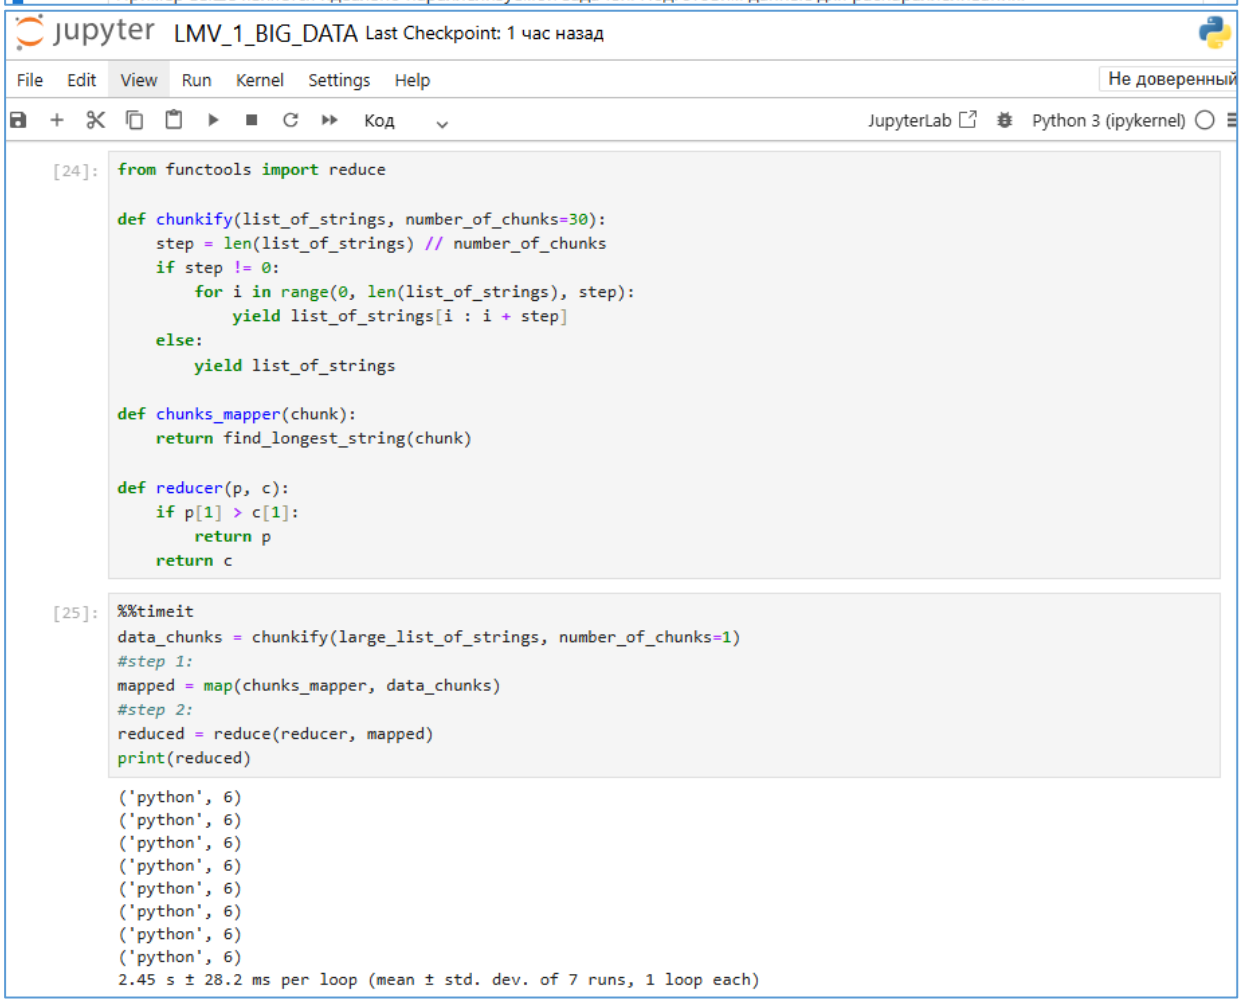

jupyter LMV_1_BIG_DATA Last Checkpoint: 1 час назад

File Edit View Run Kernel Settings Help Не доверенны

Уценка JupyterLab Python 3 (ipykernel)

[26]:
```
%%timeit
data_chunks = chunkify(large_list_of_strings, number_of_chunks=2)
#step 1:
mapped = map(chunks_mapper, data_chunks)
#step 2:
reduced = reduce(reducer, mapped)
print(reduced)
```

```
('python', 6)
('python', 6)
('python', 6)
('python', 6)
('python', 6)
('python', 6)
('python', 6)
('python', 6)
2.44 s ± 16.6 ms per loop (mean ± std. dev. of 7 runs, 1 loop each)
```

Наши данные, в среднем, обсчитываются за 2.44 с.

jupyter LMV_1_BIG_DATA Last Checkpoint: 1 час назад

File Edit View Run Kernel Settings Help Не доверенны

Код JupyterLab Python 3 (ipykernel)

Наши данные, в среднем, обсчитываются за 2.44 с.

[27]:
```
from joblib import Parallel, delayed
```

```
---------------------------------------------------------------------------
ModuleNotFoundError                       Traceback (most recent call last)
Cell In[27], line 1
----> 1 from joblib import Parallel, delayed

ModuleNotFoundError: No module named 'joblib'
```

jupyter LMV_1_BIG_DATA Last Checkpoint: 1 hour ago

File Edit View Run Kernel Settings Help Not Truste

Markdown JupyterLab Python 3 (ipykernel)

Подготовка окружения

[29]:
```
!pip install joblib
```

```
Collecting joblib
  Downloading joblib-1.5.0-py3-none-any.whl.metadata (5.6 kB)
Downloading joblib-1.5.0-py3-none-any.whl (307 kB)
Installing collected packages: joblib
Successfully installed joblib-1.5.0
```

jupyter LMV_1_BIG_DATA Last Checkpoint: 1 hour ago

File Edit View Run Kernel Settings Help Not Truste

Markdown JupyterLab Python 3 (ipykernel)

[30]:
```
from joblib import Parallel, delayed
```

[31]:
```
%%timeit
N = 2
data_chunks = chunkify(large_list_of_strings, number_of_chunks=N)
#step 1:
mapped = Parallel(n_jobs=N)(delayed(chunks_mapper)(chunk) for chunk in data_chunks)
#step 2:
reduced = reduce(reducer, mapped)
```

```
877 ms ± 6.58 ms per loop (mean ± std. dev. of 7 runs, 1 loop each)
```

В два потока стало считать быстрее. Но из-за ограничений colab мы не можем полноценно воспрользоваться мультипоточностью, попробуйте на личном компьютере какой у вас будет прирост (у меня 1.29 против 1.74, а в 4 потока считается за 0.7 секунды)?

jupyter LMV_1_BIG_DATA Last Checkpoint: 2 hours ago

File Edit View Run Kernel Settings Help Not Trusted

Code JupyterLab Python 3 (ipykernel)

[32]:
```
%%timeit
N = 4
data_chunks = chunkify(large_list_of_strings, number_of_chunks=N)
#step 1:
mapped = Parallel(n_jobs=N)(delayed(chunks_mapper)(chunk) for chunk in data_chunks)
#step 2:
reduced = reduce(reducer, mapped)
```

```
482 ms ± 10.3 ms per loop (mean ± std. dev. of 7 runs, 1 loop each)
```

[33]:
```
%%timeit
N = 8
data_chunks = chunkify(large_list_of_strings, number_of_chunks=N)
#step 1:
mapped = Parallel(n_jobs=N)(delayed(chunks_mapper)(chunk) for chunk in data_chunks)
#step 2:
reduced = reduce(reducer, mapped)
```

```
299 ms ± 14.1 ms per loop (mean ± std. dev. of 7 runs, 1 loop each)
```

[36]:
```
%%timeit
N = 12
data_chunks = chunkify(large_list_of_strings, number_of_chunks=N)
#step 1:
mapped = Parallel(n_jobs=N)(delayed(chunks_mapper)(chunk) for chunk in data_chunks)
#step 2:
reduced = reduce(reducer, mapped)
```

```
262 ms ± 8.95 ms per loop (mean ± std. dev. of 7 runs, 1 loop each)
```

[35]:
```
%%timeit
N = 10
data_chunks = chunkify(large_list_of_strings, number_of_chunks=N)
#step 1:
mapped = Parallel(n_jobs=N)(delayed(chunks_mapper)(chunk) for chunk in data_chunks)
#step 2:
reduced = reduce(reducer, mapped)
```

```
272 ms ± 11.6 ms per loop (mean ± std. dev. of 7 runs, 1 loop each)
```

Домашняя работа

Ознакомьтесь с библиотеками для распараллеливания задач в Python:

1.multiprocessing
2.joblib
3.dask

Условия и критерии выполнения домашнего задания внутри файла

---

1. MULTIPROCESSING

Модуль multiprocessing в Python позволяет запускать несколько процессов одновременно для параллельного выполнения задач. Каждый процесс имеет собственную память и независимое выполнение, в отличие от потоков, которые работают в рамках одного процесса.

Это позволяет обходить ограничение Global Interpreter Lock (GIL), что даёт возможность эффективно использовать многоядерные процессоры.

Основные понятия

Некоторые ключевые элементы модуля multiprocessing:

Класс Process — для создания и управления процессами. Позволяет запускать функции в новом процессе.

Класс Pool — предоставляет пул процессов для выполнения задач параллельно. Позволяет распределять задачи между процессами.

Класс Queue — для обмена данными между процессами через очередь.

Классы Lock, Event, Condition, Semaphore — для синхронизации процессов и предотвращения состязаний при доступе к общим ресурсам.

Преимущества и недостатки

Преимущества:

- истинный параллелизм для CPU-задач;
- изоляция процессов (сбой в одном не влияет на другие).

Недостатки:

- высокие накладные расходы на создание процессов;
- сложности с обменом данными (требуется сериализация через pickle);
- большее потребление памяти.

Примеры использования

Модуль multiprocessing подходит для работы с CPU-зависимыми задачами, такими как сложные вычисления, обработка изображений, научные расчёты. Также его можно использовать для распараллеливания большого объёма данных или ускорения итераций тяжёлых циклов.

Если основная нагрузка связана с вводом-выводом (например, сетевые запросы или работа с файлами), лучше использовать асинхронное программирование или многопоточность.

2. JOBLIB

Joblib — библиотека для распараллеливания задач в Python, которая предоставляет инструменты для параллельных вычислений, кэширования и эффективной обработки данных.

Основные функции и возможности

Распараллеливание вычислений с помощью класса Parallel. Он позволяет распределить выполнение итераций цикла или вызовы функций на несколько ядер процессора.

Кэширование результатов с помощью класса Memory. При повторном вызове функции с одинаковыми аргументами результат не вычисляется заново, а возвращается из кэша.

Сохранение и загрузка объектов Python с помощью функций joblib.dump() и joblib.load(). Поддерживаются различные методы сжатия данных, например zlib, gzip, bz2, xz.

Примеры использования

Распараллеливание цикла. Например, вычисление квадратного корня для каждого элемента списка чисел. Без параллельных вычислений это работает последовательно, а с помощью Joblib можно распараллелить цикл.

Параллельная загрузка файлов. Например, импорт нескольких файлов CSV или Excel. Joblib позволяет распределить задачи между несколькими ядрами или потоками, сократив общее время загрузки.

3. DASK

Dask — библиотека Python для параллельных вычислений и масштабируемой обработки данных. Она позволяет работать с данными, которые не помещаются в оперативную память, и исполнять задачи распределённо на многопроцессорных машинах или кластерах.

Основные возможности

Разбиение данных на части (чанки) для параллельной обработки.

Поддержка ленивых вычислений — операции выполняются только при необходимости.

Интеграция с другими библиотеками Python, такими как Pandas, NumPy и Scikit-learn.

Масштабируемость — работа от одного ядра до кластера.

Визуализация вычислений и мониторинг в браузере.

Установка и подключение

Установка можно использовать пакетный менеджер pip или conda. Например, в дистрибутиве Anaconda Dask установлен по умолчанию.

Подключение осуществляется через импорт модулей, например import dask.dataframe as dd или import dask.array as da.

Примеры использования

Обработка большого CSV-файла. Вместо загрузки всего файла в память Dask загружает его частями, а затем выполняет параллельные операции, такие как фильтрация и группировка.

Анализ логов веб-сервера. Например, подсчёт количества запросов к каждой странице.

Обработка финансовых данных для вычисления скользящего среднего.

PYTHON

```
import json
from pathlib import Path
from functools import reduce

# Функция mapper: извлекает оценку и вычисляет промежуточные значения
def mapper(path):
    n, mean, M2 = 0, 0.0, 0.0
    if path.is_file() and path.suffix == '.json':
        with open(path, 'r') as f:
            info = json.load(f)
        score = float(info['movieIMDbRating'])
        n += 1
        delta = score - mean
        mean += delta / n
        M2 += delta * (score - mean)
    return n, mean, M2

# Функция reducer: объединяет промежуточные результаты
def reducer(score_data1, score_data2):
    n1, mean1, M21 = score_data1
    n2, mean2, M22 = score_data2

    n = n1 + n2
    if n == 0:
        return 0, 0.0, 0.0

    delta = mean2 - mean1
    mean = mean1 + delta * n2 / n
    M2 = M21 + M22 + delta ** 2 * n1 * n2 / n

    return n, mean, M2

# Измерение времени выполнения всего кода
%%time

# Применяем mapper и объединяем результаты с помощью reducer
n, mean, M2 = reduce(reducer, map(mapper, Path('imdb-user-reviews').glob('**/*')))

# Выводим результат
if n > 0:
    print(f"Среднее: {mean}, Стандартное отклонение: {(M2 / n) ** (1/2)}")
else:
    print("Нет данных для обработки")
```

Ссылка на репозиторий:
https://github.com/olgashenkel/GeekBrains-specialization-ELECTIVES/tree/main/12.%20Introductory%20course%20on%20Big%20Data